

推測統計(検定)

Code ▼

inferential statistics

推測統計

少ない data から大きな集団の特徴を掴む

母集団と標本とサンプリング



推定・検定

母集団と標本

- 母集団 → 情報を得たい対象全体
- 標本 → 母集団の一部

標本抽出のサンプリング

母集団	標本
母平均： μ	標本平均： \bar{X}
母分散： σ^2	標本分散： s^2
母標準偏差： σ	標本標準偏差： s

仮説検定

ある仮説が偶然起こった事なのか **統計学的** に判断する方法

推定と同様に **標本分布** を元に考える



仮説

検定の考え方

1. 帰無仮説： H_0

- 本当は **対立仮説** を言いたい, 逆の仮説を立てる

2. 対立仮説： H_1

- 本来自分が言いたい仮説

3. 有意水準の決定(危険率, 棄却率)

- よくある事と珍しい事の%
 - 珍しい事が起これば **帰無仮説** が棄却 **対立仮説** を採択
 - よくある事が起これば **対立仮説** が棄却 **帰無仮説** を採択
 - 帰無仮説 H_0 : 正規分布の 95% の範囲に入るはず
 - 対立仮説 H_1 : 正規分布の 5% の範囲に入るはず

上記の仮説 (検定) の仕方は **片側検定**

↓

正規分布のグラフの片側の面積

違う仮説の立て方で **両側検定** もある

↓

正規分布のグラフの両側の面積

標準化

=

$$\frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

仮定

近所の酒屋でお酒の量り売りをしているが、最近お酒の量が減った気がする。100gのお酒を30日間買って量を測ったところ、平均値が98g、標準偏差が5gだった。

Hide

```
xb <- 98
s <- 5
m <- 100
n <- 30

z <- (xb - m)/(s/sqrt(n))
z
```

[1] -2.19089

- $\overline{X} : 98$ | $\mu : 100$ | $\sigma : 5$ | $\sqrt{n} : 30$

標準化

=

$$\frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

- pnorm()** : 正規分布の面積を求める
 - マイナス記号の場合は片側検定の面積

Hide

```
pnorm(-1.64, mean = 0, sd = 1)
```

[1] 0.05050258

- qnorm()** : 上記の%となる点を見つけてくれる

Hide

```
qnorm(0.05, mean = 0, sd = 1)
```

[1] -1.644854

推定と検定のまとめ

統計量が異なるとそれぞれ異なる **標本分布** が必要

母集団のどのような統計量を求めたいのか?sample数の大きさ etc



上記のような基準を常に意識して区間推定をする

	sample数小	sample数大
母平均	t 分布	正規分布 (t 分布)
母分散 (母標準偏差)	χ^2 分布 (カイ二乗分布)	χ^2 分布 (カイ二乗分布)
母比率	F 分布	正規分布

t分布を使用した検定

- 同時に区間推定もしてくれる
 - 95%の信頼区間** : 95.68908 ~ 99.91539

Hide

```
x <- rnorm(30, mean = 98, sd =5)

t.test(x, conf.level = 0.95)
```

One Sample t-test

data: x
t = 94.659, df = 29, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
95.68908 99.91539
sample estimates:
mean of x
97.80224

t分布検定

- 母平均が 100 の時に片側検定（下側）

Hide

```
t.test(x, mu = 100, alternative = "less")
```

One Sample t-test

data: x
t = -2.1271, df = 29, p-value = 0.02102
alternative hypothesis: true mean is less than 100
95 percent confidence interval:
-Inf 99.55779
sample estimates:
mean of x
97.80224

両側検定

Hide

```
t.test(x, mu = 100)
```

One Sample t-test


data: x
t = -2.1271, df = 29, p-value = 0.04204
alternative hypothesis: true mean is not equal to 100
95 percent confidence interval:
95.68908 99.91539
sample estimates:
mean of x
97.80224

sample数の変化と区間の関係

- **r** = 推定区間
- **nn1** = sample数

Hide

```
nn1 <- c(1:600)
r <- 1.96*(10/sqrt(nn1))
plot(nn1, r, type = "l")
```




sample数が増えるに従って推定区間が

plot 拡大

Hide

```
plot(nn1, r, type = "l", xlim = c(0, 20))
```



ある程度母集団の標準偏差が推定される場合は

sample数を求める為に区間を基準に決めることが出来る